

TRAFİK İŞARETİ TANIMA SİSTEMİ

Bahadır Karşı

1. GİRİŞ VE PROJE AMACI

1.1. Projenin Tanımı

Bu proje, otonom sürüş teknolojileri ve Gelişmiş Sürücü Destek Sistemleri (ADAS) kapsamında, araç kameralarından elde edilen görüntülerin işlenerek trafik işaretlerinin (hız limitleri, dur uyarıları, yön levhaları vb.) ileride otomatik olarak sınıflandırılmasını amaçlayan bir yapay zeka sistemidir.

1.2. Seçilme Gerekçesi ve Önemi

Günümüzde meydana gelen trafik kazalarının %90'ından fazlası insan hatasından (dikkatsizlik, yorgunluk, kural ihlali) kaynaklanmaktadır. Sürücülerin trafik levhalarını gözden kaçırmaları, zincirleme kazalara yol açabilmektedir. Bu projenin seçilme nedenleri şunlardır:

- Sürüş Güvenliği:** Sürücüyü görsel ve işitsel olarak uyararak kaza riskini minimize etmek.
- Otonom Sürüş Altyapısı:** Tam otonom araçların trafik kurallarına uyması için çevreyi doğru algılaması zorunluluğu.
- Teknolojik Yetkinlik:** Bilgisayarlı Görü (Computer Vision) alanındaki en güncel yöntemlerin somut bir probleme uygulanması.

1.3. Literatür Özeti

Geçmiş çalışmalarda trafik işareti tanıma problemi için renk bazlı ayrıştırma (Color Thresholding) veya HOG (Histogram of Oriented Gradients) özellik çıkarımı ile SVM (Destek Vektör Makineleri) sınıflandırıcıları kullanılmıştır. Ancak bu yöntemler gece sürüşlerinde, gölgeli alanlarda ve karmaşık arka planlarda yetersiz kalmaktadır.

Literatürdeki güncel çalışmalar (örn. Cireşan ve ark., 2012), Evrişimli Sinir Ağları'nın (CNN) insan performansını (%98.8) yakaladığını göstermektedir. Bu projede, yüksek doğruluk ve gürültüye dayanıklılık sağlayan CNN mimarisi tercih edilmiştir.

2. MATERYAL VE YÖNTEM

2.1. Veri Seti (Dataset)

Projede, akademik çalışmalarda uluslararası standart kabul edilen **German Traffic Sign Recognition Benchmark (GTSRB)** veri seti kullanılmıştır. Veri setinin temel özellikleri şunlardır:

- Sınıf Sayısı:** 43 farklı trafik işareti sınıfı.

- **Görüntü Sayısı:** 39.000+ Eğitim, 12.000+ Test görüntüsü.
- **Çeşitlilik:** Görüntüler farklı ışık koşullarında, bulanık veya kısmen kapanmış hallerde bulunmaktadır, bu da modelin gerçek hayata uygunluğunu artırır.



Şekil 1: GTSRB Veri Setinden Örnek Trafik İşaretleri

2.2. Veri Ön İşleme (Preprocessing)

Ham veri setini modelin işleyebileceği formata getirmek için aşağıdaki adımlar uygulanmıştır:

1. **Boyutlandırma (Resizing):** Tüm görüntüler standart olarak 32×32 piksel boyutuna getirilmiştir.
2. **Normalizasyon:** Piksel değerleri, modelin daha hızlı ve kararlı öğrenmesi için $[-1, 1]$ aralığına ölçeklendirilmiştir.
3. **Tensör Dönüşümü:** Görüntüler PyTorch kütüphanesine uygun tensör formatına çevrilmiştir.

2.3. Yöntem Seçimi ve Karşılaştırma

Görüntü verisindeki mekansal özellikleri (kenar, köşe, doku) en iyi yakalayan mimari olduğu için **Evrişimli Sinir Ağları (CNN)** tercih edilmiştir. Diğer yöntemlerle karşılaştırması Tablo 1'de verilmiştir.

Tablo 1: Yöntemlerin Karşılaştırmalı Analizi

Yöntem	Özellik Çıkarımı	Başarı Potansiyeli	Avantaj/Dezavantaj
KNN	Piksel bazlı uzaklık	Düşük	Görüntü kaydırmalarına karşı çok hassas ve yavaş.
MLP (YSA)	Düzleştirilmiş vektör	Orta	Mekansal bilgiyi kaybeder, piksellerin komşuluğunu anlamaz.
CNN (Seçilen)	Otomatik Filtreleme	Yüksek	Konumdan bağımsız (Translation Invariance) özellik yakalar.

2.4. Model Mimarisi

PyTorch kütüphanesi kullanılarak tasarlanan CNN modeli şu katmanlardan oluşmaktadır:

- **2 Adet Evrişim (Conv2d) Katmanı:** Görüntüden öznitelik haritaları çıkarır.
- **Aktivasyon Fonksiyonu (ReLU):** Doğrusal olmayan ilişkileri öğrenir.
- **Havuzlama (MaxPooling):** Görüntü boyutunu küçülterek işlem yükünü azaltır.
- **Dropout (0.5):** Aşırı öğrenmeyi (Overfitting) engellemek için nöronların %50'si rastgele kapatılır.
- **Tam Bağlantılı (Fully Connected) Katmanlar:** Sınıflandırma kararını verir.

3. DENEYSEL BULGULAR VE MODEL DEĞERLENDİRMESİ


3.1. Eğitim Parametreleri

Model eğitimi, Google Colab ortamında GPU hızlandırması kullanılarak gerçekleştirilmiştir.

- **Epoch Sayısı:** 10
- **Batch Size:** 64
- **Learning Rate:** 0.001
- **Optimizer:** Adam
- **Loss Function:** Cross Entropy Loss

3.2. Eğitim Grafikleri

Eğitim süresince elde edilen Kayıp (Loss) ve Doğruluk (Accuracy) değerlerinin değişimi Şekil 2'de verilmiştir. Grafikler incelendiğinde, kaybın düzenli olarak azaldığı ve doğruluğun arttığı, modelin sağlıklı bir öğrenme süreci geçirdiği görülmektedir.



Şekil 2: Eğitim Sürecindeki Kayıp ve Doğruluk Grafikleri

3.3. Performans Sonuçları


Eğitim tamamlandıktan sonra, modelin hiç görmediği Test Veri Seti üzerinde yapılan değerlendirme sonuçları şöyledir:

- **Genel Test Doğruluğu (Accuracy): %95.95**
- **F1-Score (Ağırlıklı Ortalama): 0.96**

Bu sonuç, modelin sadece veriyi ezberlemediğini (overfitting yapmadığını), genelleme yeteneğinin yüksek olduğunu kanıtlamaktadır.

3.4. Karmaşıklık Matrisi (Confusion Matrix) Analizi


Modelin hangi sınıfları karıştırdığını analiz etmek için oluşturulan Karmaşıklık Matrisi Şekil 3'te sunulmuştur. Matrisin diyagonal (köşegen) eksenindeki yoğunluk, doğru tahminlerin başarısını göstermektedir. Hataların genellikle birbirine çok benzeyen levhalar (örn: 30 km/s hız sınırı ile 50 km/s hız sınırı) arasında olduğu tespit edilmiştir.



Şekil 3: Modelin Karmaşıklık Matrisi

3.5. Gerçek Hayat Senaryosu (Demo)

Modelin gerçek dünya performansını ölçmek amacıyla, veri setinde bulunmayan ve internetten rastgele indirilen 4 adet trafik işareti görüntüsü (Dur Levhası, Hız Limiti vb.) modele sunulmuştur. Model, bu görüntülerin tamamını doğru sınıflandırarak **%100 başarı** göstermiştir.



Şekil 4: Dış Kaynaklı Görüntülerle Yapılan Tahmin Sonuçları

4. SONUÇ VE ÖNERİLER

Bu proje kapsamında, otonom araç güvenliği için kritik öneme sahip olan trafik işareti tanıma sistemi, Derin Öğrenme yöntemleri kullanılarak başarıyla geliştirilmiştir. PyTorch kütüphanesi ile oluşturulan Evrişimli Sinir Ağı (CNN) modeli, **%95.95** gibi yüksek bir doğruluk oranına ulaşmıştır.

Elde edilen bulgular, CNN mimarisinin görüntü sınıflandırma problemlerinde geleneksel yöntemlere göre çok daha üstün olduğunu doğrulamaktadır. Projenin ilerleyen aşamalarında, benzer levhaların karışmasını önlemek için daha derin ağ mimarilerinin (örn. ResNet) kullanılması ve sistemin statik görüntüler yerine video akışı üzerinde gerçek zamanlı çalıştırılması hedeflenmektedir.

5. KAYNAKÇA

1. Stallkamp, J., Schlipsing, M., Salmen, J., & Igel, C. (2012). The German Traffic Sign Recognition Benchmark: A multi-class classification competition. *Hinged Neural Networks*.
2. LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
3. PyTorch Documentation. (2024). <https://pytorch.org/docs/stable/index.html>